



Universidad Politécnica Internacional

Machine Learning

Proyecto

Análisis y Comparación de Algoritmos de Clasificación para la
Predicción del Rango de Precio de Teléfonos Móviles con Orange.

2025

Estudiantes

Nathalie González Chaves

Jessica Velásquez Ulate

Gerson Daniel Leal Barboza

Profesor

Andres Zúñiga Umaña

Exploración & Preprocesamiento

Nuestro objetivo con este primer avance fue completar la exploración inicial y el preprocesamiento de un dataset con 2000 registros y 21 atributos la clasificación de precios de celulares relacionados a características como capacidad de batería, memoria interna, conectividad, entre otros. La variable que escogimos como target es el rango de precio (price_range).

La exploración de los datos la iniciamos con la conexión a los datos brutos y la generación de gráficos de dispersión para la detección de outliers.

Nuestro hallazgo principal fue la fuerte correlación que encontramos entre las características y el target. Específicamente, la memoria RAM nos mostró una influencia mucho más marcada en el rango de precio que cualquier otro atributo, incluyendo la capacidad de la batería (battery_power).

En la fase de calidad de datos, utilizamos el widget Select Rows para verificar la ausencia de valores nulos al utilizar la condición "Todas las variables están definidas". Nuestro workflow muestra un widget de "Impute", pero basándonos en el informe de "0% nulos", este paso resultó ser innecesario para este dataset específico.

Continuando en la etapa de limpieza, normalizamos los datos numéricos mediante Continúe. Con este último paso, nos aseguramos que todas las características tengan la misma escala, preparando así el dataset para las futuras etapas de modelado sin sesgos por magnitud.

Modelado & Validación:

En el Modelado de los datos decidimos incluir todas las 20 variables dentro de los modelos ya que luego de que realizáramos pruebas con cada una de ellas no tenía relevancia eliminar ninguna. Se evaluaron cuatro modelos: Random Forest, kNN, Tree (Árbol de Decisión), y Naive Bayes, y utilizando un Data Sampler seleccionamos la opción para que cada modelo utilizara un 80% de los datos en cada prueba.

Model	AUC	CA	F1	Prec	Recall	MCC
Random Forest	0.936	0.780	0.776	0.775	0.780	0.708
kNN	0.993	0.918	0.919	0.920	0.918	0.892
Tree	0.911	0.850	0.849	0.852	0.850	0.801
Naive Bayes	0.899	0.740	0.741	0.742	0.740	0.654

Nosotros nos basamos en las métricas anteriores para tomar la decisión final sobre cual modelo utilizaríamos para este proyecto, para esto realizamos estas comparaciones:

- El modelo kNN supera a los demás modelos en todas las métricas clave (AUC=0.993, Accuracy=0.924, F1=0.924, MCC=0.898). Una precisión, *recall* y *F1-score* superiores a 0.92 es excelente. indica una capacidad casi perfecta para distinguir entre los rangos de precio. Concluimos que tiene un rendimiento superior.
- Los modelos Tree y Random Forest nos ofrecieron un rendimiento sólido, especialmente Tree, con una Precisión del 85.2%. Nos sorprendió que en este caso Random Forest rinde peor que el kNN individual en este caso. Concluimos que tienen un rendimiento decente.
- El modelo Naive Bayes es el modelo con el que obtuvimos un desempeño más débil (Accuracy=0.730), probablemente porque su suposición de independencia de características no se cumple en este dataset, debido a la correlación entre RAM y el `price_range`. Concluimos que tienen un rendimiento bajo.

Durante el flujo de trabajo en la herramienta, tras realizar pruebas de evaluación comparativa con el widget Test & Score, determinamos que el modelo kNN demostró el mejor desempeño general, superando en precisión y estabilidad a los demás algoritmos.

Entendemos que la razón por la cual nos resultó particularmente eficaz es porque los datos de nuestro dataset asignado tiene una estructura muy bien definida, de igual manera creemos que tambien nos funcionó a la perfección ya que logramos normalizar de forma correcta las variables utilizadas. Debido al análisis que realizamos llegamos a la conclusion de que el modelo con el mejor rendimiento general es kNN (k-Nearest Neighbors).

En nuestra opinión el modelo kNN presenta el un mayor poder predictivo y una mayor capacidad de generalización para nuestro problema. Nos enfocamos específicamente en el AUC de 0.993 que nos dice que es el modelo más discriminativo, la Precisión (CA) de 0.924, lo cual significa que nos va a clasificar correctamente la categoría de precio de un nuevo celular el 92.4% de las veces y finalmente, observamos que el MCC de 0.898 es el más alto entre los demás modelos, confirmándonos que el modelo es robusto y no solo está acertando por casualidad o por un desbalance de clases.

Optimización

Model	AUC	CA	F1	Prec	Recall	MCC
Random Forest	0.944	0.793	0.793	0.794	0.793	0.725
kNN	0.993	0.923	0.924	0.926	0.923	0.898
Tree	0.911	0.850	0.849	0.852	0.850	0.801
Naive Bayes	0.906	0.730	0.731	0.733	0.730	0.640

Model	AUC	CA	F1	Prec	Recall	MCC
Random Forest Optimizado	0.969	0.848	0.848	0.849	0.848	0.798
kNN Optimizado	0.961	0.888	0.888	0.891	0.888	0.852
Tree Optimizado	0.950	0.868	0.868	0.869	0.868	0.825

En la primera imagen podemos ver el rendimiento inicial de nuestros modelos de clasificación, para optimizar los modelos y obtener los resultados de la segunda imagen, se realizaron ajustes a los siguientes hiperparámetros:

Con el kNN inicialmente utilizamos la regla empírica de que K es igual a la raíz cuadrada del número de filas de entrenamiento. Al realizar la ecuación obtenemos como resultado 44.7. Este valor es extremadamente grande para nuestro dataset. Por lo tanto debido a que el modelo inicial nos había dado un valor bastante bueno con un valor de K de 12, decidimos utilizar valores menores a 12 hasta llegar al número 2 donde descubrimos que nos daba el mejor balance.

Luego con el Random Forest la optimización la hicimos para que el modelo fuera más grande y más robusto, mientras que simultáneamente lo hacíamos más conservador y menos propenso al sobreajuste. Ya que decidimos aumentar la cantidad de árboles de 10 a 40 y al mismo tiempo mejoramos el control de crecimiento al aumentar No dividir subconjuntos menores que de 5 a 15. Esta combinación tuvo como consecuencia que el Random Forest Optimizado se convirtiera en nuestro mejor modelo en términos de capacidad de discriminación con un AUC de 0.969

Finalmente, la optimización del modelo Tree consistió en que restringimos severamente el crecimiento del árbol para que solo se enfocara en las reglas más importantes. El modelo inicial tenía una profundidad casi ilimitada de 100 y criterios de división de 2 y 5 por lo que notamos que estaba sobre ajustado. Cambiamos los datos en un formato de prueba y error hasta que llegamos a los nuevos límites de 10 de profundidad y de 7 y 10 en las divisiones. Con esto forzamos al árbol a que fuera un modelo más simple y más robusto que pudimos ejemplificar con un MCC que pasó de 0.801 a 0.825.

Interpretabilidad

Durante el desarrollo del modelo predictivo para estimar el rango de precios de teléfonos móviles, se utilizaron los algoritmos Naive Bayes, Random Forest, K-Nearest Neighbors/Knn y el Árbol de decisión. El objetivo fue determinar que variables influyen más en el precio final y justificar las decisiones de eliminación o conservación de columnas.

El conjunto de datos incluía atributos técnicos del dispositivo, como: battery_power, ram, int_memory, mobile_wt, px_height, talk_time, n_cores, clock speed, dual_sim, entre otros.


La variable objetivo definida desde un principio fue price_range, con cuatro niveles de precio.

Se hicieron observaciones y pruebas exploratorias. Sin embargo, dado que los algoritmos seleccionados manejan correctamente variables numéricas y categóricas y que cada atributo aporta información distinta del rendimiento del móvil, no se eliminaron columnas del dataset original.

Una vez que utilizamos los algoritmos notamos lo siguiente:

- El análisis de importancia de atributos del modelo Random Forest mostró que las variables ram, battery_power, px_height y px_width son las más determinantes para clasificar el rango de precio.
- El Arbol de decisión, pudimos notar como las reglas principales de decisión se basaron en ram y battery_power.

Entonces en resumen, optamos por mantener todos los atributos originales principalmente por el aporte informativo y la estabilidad del desempeño de los modelos.



Como el modelo toma decisiones clave?

Quisimos analizar el comportamiento del modelo Arbol de decisión. El modelo analiza variables con mayor poder predictivo. En este caso la primera división del árbol ocurre sobre la variable ram, lo que indica que esta característica es la mas influyente.

Por ejemplo:

Si el teléfono tiene una RAM mayor a 2000 MB, el modelo lo dirige hacia una categoría de precio alto o muy alto. Si es mejor a esa cantidad, el modelo busca evaluar otra variable tal como battery_power, si esta variable es mayor que 1000 mAh, clasifica el dispositivo como precio medio y si la variable es menor que eso, el modelo busca y revisa otras variables alternativas.

Conclusiones Técnicas

Dado los resultados obtenidos, recomendamos la implementación del modelo kNN Optimizado porque es el modelo más robusto y fiable, logrando el mejor balance general

Entre las limitaciones del modelo kNN, se encuentra que el rendimiento del modelo depende directamente del número de vecinos y del tipo de métrica de distancia utilizada. Una elección inadecuada de estos parámetros puede afectar la precisión del modelo. Lo notamos muy sensible lo que representa un riesgo de inestabilidad si los datos cambian.

Como mejora futura, recomendamos aplicar algún proceso sistemático de optimización de hiperparámetros, con algún otro tipo de widget de Orage, explorando distintos valores de k y métricas de distancia (Euclidean, Manhattan, Minkowski).